

Un modello statistico per la previsione del peso dei neonati

Matteo M. Costa

17 Aprile 2024

Sommario

In queste pagine viene presentato la costruzione di un modello statistico per la previsione del peso dei neonati partendo da un campione di studio composto da 2500 nati per i quali vengono specificate variabili informative a carattere qualitativo e quantitativo. Utilizzando note tecniche di statistica inferenziale implementate in linguaggio R, si cercherà di determinare vari modelli col fine di stabilire quello più performante tra quelli analizzati.

1 Data exploring

In questa sezione iniziamo a esplorare il dataset *neonati.csv* che può essere importato tramite la function *read.csv*. Tramite le function *dim* o *str* possiamo estrarre informazioni relative alla dimensione del dataset e al tipo di variabili in esso contenute:

```
#Libraries
library (ggplot2)
library (dplyr)
library (tidyverse )
library ( lubridate )
library (zoo)

#Import csv
path = "... \ neonati.csv"
data_peso = read.csv(path)
str (data_peso)
```

La variabile *path* contiene il percorso di salvataggio del file csv mentre l'output della function *str* è riportato di seguito. Si ha la presenza di 2500 record per un totale di 10 variabili distinte:

```
> str (data_peso)
'data.frame': 2500 obs. of 10 variables :
 $ Anni.madre : int 26 21 34 28 20 32 26 25 22 23 ...
 $ N.gravidanze: int 0 2 3 1 0 0 1 0 1 0 ...
 $ Fumatrici : int 0 0 0 0 0 0 0 0 0 0 ...
 $ Gestazione : int 42 39 38 41 38 40 39 40 40 41 ...
 $ Peso : int 3380 3150 3640 3690 3700 3200 3100 3580 3670 3700 ...
 $ Lunghezza : int 490 490 500 515 480 495 480 510 500 510 ...
 $ Cranio : int 325 345 375 365 335 340 345 349 335 362 ...
 $ Tipo.parto : chr "Nat" "Nat" "Nat" "Nat" ...
 $ Ospedale : chr "osp3" "osp1" "osp2" "osp2" ...
 $ Sesso : chr "M" "F" "M" "M" ...
```

Nello specifico, il dataset contiene dati raccolti relativi a tre ospedali su un totale di 2500 neonati. In particolare, ogni record rappresenta una specifica nascita; abbiamo le seguenti variabili:

1. *Anni.madre*: età della madre;
2. *N.gravidanze*: numero di gravidanze sostenute prima di quella registrata (ad es. lo 0 specifica che la madre è alla sua prima gravidanza, se 1 la madre è alla sua seconda gravidanza e così via);
3. *Fumatrici*: madre fumatrice (flag pari a 0 o 1 per NO o SI rispettivamente);
4. *Gestazione*: numero di settimane di gestazione del nascituro;
5. *Peso*: peso (massa) in grammi del neonato;
6. *Lunghezza*: lunghezza in mm del neonato;
7. *Cranio*: diametro in mm del cranio del neonato;
8. *Tipo.parto*: tipologia di parto (flag *Nat* o *Ces* per naturale o cesareo);
9. *Ospedale*: ospedale di nascita (flag *osp1*, *osp2* o *osp3*);
10. *Sesso*: sesso del neonato (flag pari a *M* o *F* per maschio o femmina rispettivamente).

Nello specifico, possiamo classificare le variabili nel modo seguente:

1. quantitative continue: *Peso*, *Lunghezza*, *Cranio*, *Anni.madre*, *Gestazione*;
2. quantitative discrete: *N.gravidanze*;
3. qualitative categoriali: *Tipo.parto*, *Ospedale*, *Fumatrici*, *Sesso*.

2 Data cleaning

Prima di addentrarci a un'analisi descrittiva vera e propria, iniziamo a indagare la presenza di eventuali dati spuri e di valutarne il loro trattamento. Di seguito uno studio sulle frequenze assolute per quelle variabili che potrebbero causare problemi; tra queste troviamo anche quelle che sono valorizzate tramite flag (*Tipo.parto*, *Ospedale*, *Fumatrici*, *Sesso*) per le quali vogliamo essere certi della valorizzazione consentita dal dataset. Per la costruzione degli istogrammi abbiamo utilizzato il seguente codice (in questo esempio l'istogramma è compilato sulla variabile *Ospedale*):

```
#Histogram
personal_theme = theme(plot.title = element_text(hjust = 0.5))

ggplot(data=data_peso, aes(x = Ospedale)) +
  geom_bar(col = "black", fill = "blue") +
  geom_text(stat='count', aes(label = ..count ..),
            vjust = -0.3, position = position_dodge(width = 0.9)) +
  scale_y_continuous() + ggtitle("Ospedale: absolute frequency distribution") +
  personal_theme
```




Figura 1: Istogramma delle frequenze assolute dell'età delle madri. Possiamo notare la presenza di due record che presentano un'età pari a 0 e 1. Scientificamente, in media, il periodo di fertilità inizia tra i 12 e i 14 anni d'età. Essendo i due record circa l'0.08% del campione, optiamo ad eliminare tali record dal dataset.




Figura 2: Istogramma delle frequenze assolute sul numero di gravidanze sostenute precedentemente per ogni singola madre; per il dataset fornito, possiamo notare che la maggior parte delle madri sono alla loro prima gravidanza, circa 1096 record su un totale di 2500 (circa il 43% del totale). Notiamo anche alcuni casi eccezionali di madri sopra alla decima gravidanza. Per quanto queste siano casistiche eccezionali ma non improbabili, le considereremo comunque all'interno del dataset.




Figura 3: La valorizzazione dei flag per le variabili *Fumatrici* e *Tipo.parto* risulta corretta; per entrambe, il totale delle casistiche ritorna sempre 2500 record totali. Possiamo osservare che le madri fumatrici sono circa il 4% del totale mentre la nascita tramite parto cesareo è stata applicata nel 29% dei casi.




Figura 4: Istogramma delle frequenze assolute della variabile *Ospedale*. Si può notare che il campione è abbastanza omogeneo sui tre ospedali. Possiamo notare che il secondo ospedale è quello in cui si sono registrate più nascite, in particolare abbiamo 33 e 14 nascite in più rispetto al primo e al terzo. Il primo ospedale risulta quello con meno nascite.




Figura 5: Anche per la variabile *Sesso* non ci sono valorizzazioni mancanti: la somma ritorna sempre i 2500 record. Dall'istogramma a destra possiamo inoltre notare come sui tre ospedali la nascita tra maschi e femmine si sia mantenuta abbastanza uniforme. In particolare il comando `data_peso %>% count(Ospedale, Sesso) %>% group_by(Ospedale)` ci consente di osservare i seguenti valori:

	osp1	osp2	osp3
M	407	414	423
F	409	435	412

Come già visto in Figura 4, il secondo ospedale è quello in cui si sono registrate più nascite; notiamo anche che l'ospedale in cui sono nati più maschi è il terzo mentre quello in cui sono nate più femmine è il secondo. Il primo ospedale si riconferma come quello con meno nascite anche rispetto al sesso dei nascituri.

2.1 Analisi descrittiva delle variabili

Per quanto osservato nella sezione precedente, da qui in poi considereremo il dataset ripulito di quei due record che presentavano *Anni.madre* pari a 0 e a 1. Per fare ciò abbiamo applicato il filtro `data_peso %>% filter(Anni.madre > 1)` sul dataset importato all'inizio. Come già osservato, il dataset contiene informazioni relative a tre ospedali: nelle tre sedi si è potuto osservare come la distribuzione delle nascite nel campione considerato fosse uniforme dall'osservazione della variabile *Sesso*. Cerchiamo ora di determinare opportuni indici di variabilità.

2.1.1 Indici di posizione e di variabilità

Per le variabili quantitative continue e discrete ha senso calcolare gli indici di posizione della media $\bar{x}$ e della mediana $\bar{m}$, definite come

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{m} := \begin{cases} x_{\frac{n+1}{2}} & n \text{ dispari} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2} & n \text{ pari} \end{cases}$$

dove $n = 2498$ rappresenta la numerosità del campione considerato $X = \{x_1, \dots, x_n\}$. Per effettuare il calcolo sulle variabili, possiamo applicare la seguente function creata in R:

```
#Position index
quantitative <- c("Anni.madre",
                 "Peso",
                 "Lunghezza",
                 "Cranio",
                 "N.gravidanze",
                 "Gestazione")
quantiv_data <- data_peso[ quantitative ]

pos_index = function(df){
  measurements = data.frame( attributes = character (),
                             mean = double (),
                             median = double ()
  )

  for (i in 1:ncol(df)){
    names = colnames(df)[ i ]
    pos_temp = data.frame( attribute = names,
                          mean = round(mean(df[,i ]), digits =2),
                          median = round(median(df[, i ]), digits =2)
    )
    measurements = rbind(measurements, pos_temp)
  }
  return (measurements)
}

pos_index(quantiv_data)
```

Si ottiene il seguente output:

```
> pos_index(quantiv_data)
  attribute    mean median
1 Anni.madre 28.19     28
```

2	Peso	3284.18	3300
3	Lunghezza	494.70	500
4	Cranio	340.03	340
5	N.gravidanze	0.98	1
6	Gestazione	38.98	39

Nel campione considerato possiamo notare che in media una nascita avviene intorno ai 28 anni di età e che il periodo di gestazione dura in media 38 settimane (circa nove mesi e mezzo). Questo dato è realistico essendo il periodo di gravidanza generalmente stimato tra le 37 e le 40 settimane. In modo analogo, indicando sempre con n la numerosità del campione considerato $X = \{x_1, \dots, x_n\}$, possiamo calcolare gli indici di variabilità con una function simile:

```
var_index = function(df){
  measurements = data.frame( attributes = character (),
                              range = double (),
                              IQR = double (),
                              variance = double (),
                              sd = double (),
                              cv = double()# Variable with bigger variability
  )
  for (i in 1:ncol(df)){
    names = colnames(df)[i]
    var_temp = data.frame( attribute = names,
                          range = round(max(df[,i]) - min(df[,i]), digits=2),
                          IQR = round(IQR(df[,i]), digits=2),
                          var = round(var(df[,i]), digits=2),
                          sd = round(sd(df[,i]), digits=2),
                          cv = round((sd(df[,i])/mean(df[,i]))*100, digits=2)
    )
    measurements = rbind(measurements, var_temp)
  }
  return (measurements)
}

var_index(quantiv_data)
```

In particolare, la function determina range interquartile, IQR, varianza σ^2 , deviazione standard σ e coefficiente di variazione cv che ricordiamo essere definiti come

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2, \quad \sigma = \sqrt{\sigma^2}, \quad cv = \frac{\sigma}{\bar{X}} 100.$$

Si ottiene il seguente output:

```
> var_index(quantiv_data)
  attribute range IQR      var      sd      cv
1 Anni.madre   33   7   27.22   5.22  18.51
2      Peso  4100 630 275865.90 525.23  15.99
3  Lunghezza   255  30   693.21  26.33   5.32
4      Cranio   155  20   269.93  16.43   4.83
5 N.gravidanze    12   1     1.64   1.28 130.50
6  Gestazione    18   2     3.49   1.87   4.79
```

Possiamo notare che la variabile quantitativa con variabilità più elevata risulta essere *N.gravidanze* essendo quella col coefficiente di correlazione cv maggiore. Notiamo

che i valori delle medie e degli indici di posizione sono stati determinati non distinguendo tra il sesso dei nati; nella sezione che segue cercheremo di esplorare altre possibili differenze significative tra i due sessi.

2.1.2 Altre differenze significative tra i due sessi

Tramite la seguente procedura di *group_by* si possono fare eventuali considerazioni sulla media delle variabili *Peso*, *Lunghezza* e *Gestazione* in base alla variabile *Sesso*:

```
data_peso %>% group_by(Sesso) %>% summarise(mean=mean(Peso))
```

#Output

Sesso	mean
<chr>	<dbl>
1 F	3161.
2 M	3408.

```
data_peso %>% group_by(Sesso) %>% summarise(mean=mean(Lunghezza))
```

#Output

Sesso	mean
<chr>	<dbl>
1 F	490.
2 M	500.

```
data_peso %>% group_by(Sesso) %>% summarise(mean=mean(Gestazione))
```

#Output

Sesso	mean
<chr>	<dbl>
1 F	38.7
2 M	39.2

Possiamo notare che in termini di media, le tre variabili analizzate si discostano di poco l'una dall'altra; rimane però evidente che i nati maschi presentano un peso maggiore alla nascita, in particolare una differenza di circa 250 grammi in più. Per i periodi di gestazione non sembra esserci una differenza temporale rilevante.

2.1.3 Osservazione sulle madri fumatrici

Possiamo osservare che la distribuzione delle madri fumatrici nei tre ospedali è abbastanza omogenea. La seguente *group_by* ci consente di eseguire un raggruppamento del flag *Fumatrici* rispetto a ogni ospedale:

```
df2 <- data_peso %>%
  count(Ospedale, Fumatrici) %>%
  group_by(Ospedale)

print(df2)
```

Otteniamo infatti il seguente output:

	osp1	osp2	osp3
0	779	813	804
1	37	36	31

3 Verifica di ipotesi

In questa sezione ci addentriamo in un cosiddetto processo di verifica di ipotesi. In particolare, cerchiamo di verificare che le medie $\hat{\mu}$ delle variabili *Peso* e *Lunghezza* del campione non siano significativamente diverse da quelle della popolazione μ_0 (i valori μ_0 della popolazione che considereremo sono tratti da noti risultati della letteratura scientifica e seguono distribuzioni normali).

In termini generali, la costruzione di una verifica di ipotesi si basa sul considerare due assunti, un'ipotesi **nulla** H_0 e un'ipotesi **alternativa** H_1 . In generale l'ipotesi nulla H_0 afferma che l'effetto mostrato dal campione è dovuto solo a una variazione casuale tra il campione e la popolazione; al contrario, H_1 rappresenta un'ipotesi logico-contraria a H_0 . Come accennato, la verifica di un'ipotesi è un processo su H_0 : si inizia a assumere vera H_0 come nella situazione in cui si considera innocente un imputato fino a prova contraria. Sarà lo studio sul campione considerato a fornire eventuali prove contrarie dall'assunto iniziale.

3.1 Verifica di ipotesi sulla media di una popolazione normale con varianza nota: il test Z

Consideriamo una popolazione normale di media μ_0 di varianza nota e assumiamo che $H_0 : \hat{\mu} = \mu_0$ sul campione $X = \{x_1, \dots, x_n\}$. Pertanto H_1 può assumere uno dei seguenti casi:

$$H_1 := \begin{cases} \hat{\mu} > \mu_0 & \text{ipotesi alternativa unidirezionale a destra} \\ \hat{\mu} < \mu_0 & \text{ipotesi alternativa unidirezionale a sinistra} \\ \hat{\mu} \neq \mu_0 & \text{ipotesi alternativa bidirezionale} \end{cases}$$

Essendo $\bar{X}$ lo stimatore non distorto per $\hat{\mu}$, è naturale che il test di ipotesi su $\hat{\mu}$ sia concentrato su $\bar{X}$. Pertanto, se assumiamo vera $H_0 : \hat{\mu} = \mu_0$, dalla teoria degli stimatori sappiamo che

$$\bar{X} \sim N\left(\mu_0, \frac{\sigma^2}{n}\right),$$

e pertanto la variabile aleatoria

$$Z_{\bar{X}} := \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1),$$

si distribuisce come una v.a. normale standardizzata. Pertanto tramite la variabile $Z_{\bar{X}}$ possiamo verificare l'ipotesi su $\hat{\mu}$ tramite una rispettiva statistica test $z_{\bar{X}}$ sul campione fissato: se assumiamo vera H_0 , la variabile $Z_{\bar{X}}$ si distribuisce come una normale. In particolare, procederemo come segue secondo una regola di decisione che tiene dunque conto della legge normale standardizzata.

3.1.1 Regola di decisione: caso $H_1 : \hat{\mu} > \mu_0$

Indicando con $\alpha \in (0, 1)$ un livello di significatività assegnato, sia

$$z_{\bar{x}} := \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}},$$

il valore assunto da $Z_{\bar{X}}$ sul campione osservato. Pertanto diremo che H_0 è da rifiutare se $z_{\bar{x}} > z_{1-\alpha}$, dove $z_{1-\alpha}$ è il quantile di livello $1 - \alpha$ della normale standard. Pertanto, l'insieme dei valori di $z_{\bar{x}}$ per cui si rifiuta l'ipotesi nulla è

$$R = \{z_{\bar{x}} : z_{\bar{x}} > z_{1-\alpha}\}.$$

Pertanto, assegnato α , si pone

$$\mathbb{P}(Z_{\bar{X}} \in R \mid H_0) = \mathbb{P}(Z_{\bar{X}} > z_{1-\alpha} \mid \hat{\mu} = \mu_0) = \alpha,$$

dove $\mathbb{P}(Z_{\bar{X}} \in R \mid H_0)$ è detta *p-value* il cui significato è immediato: se $H_0 : \hat{\mu} = \mu_0$ è vera, la probabilità che la statistica cada nella zona di rifiuto è pari a α . Empiricamente si tende a rifiutare H_0 ogni volta che il *p-value* è minore di $\alpha = 0.05$. Dal punto di vista esplicito il fondamento logico è il seguente: la disuguaglianza $z_{\bar{x}} > z_{1-\alpha}$ implica che

$$\bar{x} > \mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}},$$

ovvero si rifiuterà l'ipotesi nulla quando la media campionaria osservata è molto più grande di quella di μ_0 .

3.1.2 Regola di decisione: caso $H_1 : \hat{\mu} < \mu_0$

In modo analogo al caso precedente, la regola di decisione prevede di considerare una zona di rifiuto definita come $R = \{z_{\bar{x}} : z_{\bar{x}} < -z_{1-\alpha}\}$.




Figura 6: Grafico riassuntivo delle regole di decisione delle sezioni 3.1.1 e 3.1.2.

3.1.3 Regola di decisione: caso $H_1 : \hat{\mu} \neq \mu_0$

In questo caso, noto come *test bidirezionale*, la regola di decisione prevede di considerare la zona di rifiuto definita come

$$R = \{z_{\bar{x}} : |z_{\bar{x}}| > z_{1-\frac{\alpha}{2}}\}.$$

Qui di seguito un grafico riassuntivo della regola di decisione per lo Z-test bilaterale.




Figura 7: Grafico riassuntivo della regola di decisione per lo Z-test bilaterale. In accordo con la definizione, α è l'area del sottografo della normale in base al quantile fissato.

3.2 Analisi inferenziale sul peso

Secondo recenti studi, possiamo approssimare μ_0 come $\mu_0 = 3300$ g (si è utilizzato l'unità di misura del grammo come la variabile *Peso* del dataset). Pertanto la verifica dell'ipotesi che la media del peso del campione $\hat{\mu}$ sia significativamente uguale a quello della popolazione μ_0 , consiste nella verifica del test statistico

$$\begin{cases} H_0 : \hat{\mu} = 3300 \\ H_1 : \hat{\mu} \neq 3300 \end{cases}$$

Essendo nota la media della popolazione, possiamo effettuare uno Z-test bilaterale. Di seguito la costruzione di una function che presi in input una variabile numerica x (che rappresenta il campione), la media μ_0 e la deviazione standard $stdev$ della popolazione e un *alfa* fissato, restituisce opportune informazioni per studiare la significatività del test:

```
z_test = function(x, mu0, stdev, alfa){  
  
  x = na.omit(x) #Gestione di eventuali valori mancanti dal campione x  
  mu_cap = mean(x) #Valore campionato della media  
  n = length(x)
```

```

Z = (mu0-mu_cap)/(stdev/sqrt(n))

valori . soglia = qnorm(c(alfa /2, 1-alfa /2)) #Zona di rifiuto

# Intervallo di confidenza
CI = c(mu_cap+qnorm(alfa/2)*(stdev/ sqrt (n )),
      mu_cap-qnorm(alfa/2)*(stdev/ sqrt (n )))

return ( list (media.campionaria = mu_cap,
              stat . test = Z,
              valori . soglia = valori . soglia ,
              pvalue = 2*pnorm(-abs(Z)),
              Int . conf = CI
            )
        )
}

```

Sempre dalla letteratura scientifica, considerando $stdev = 500$ grammi, otteniamo il seguente output:

```

> z_test (data_peso$Peso, 3300, 500, 0.05)
$media.campionaria
[1] 3284.184

$stat . test
[1] 1.580953

$valori . soglia
[1] -1.959964 1.959964

$pvalue
[1] 0.1138889

$Int . conf
[1] 3264.577 3303.792

```

Alla luce di ciò possiamo osservare che il valore $\hat{\mu} = 3284.184$ appartiene all'intervallo di confidenza calcolato, il valore della statistica test non cade al di fuori dei valori di soglia e il valore del p -value è maggiore della soglia fissata a 0.05. Possiamo dedurre di non negare H_0 : la stima della media $\hat{\mu} = 3284.184$ non è significativamente diversa da quella della popolazione.

3.3 Analisi inferenziale sulla lunghezza

Applicando la medesima function della sottosezione precedente, effettiamo un ragionamento simile per la variabile *Lunghezza*. Dalla letteratura scientifica, la media della lunghezza e la rispettiva deviazione standard in mm vengono stimate a 508 e 48. Si ottiene il seguente output:

```

> z_test (data_peso$Lunghezza, 500, 70, 0.05)
$media.campionaria
[1] 494.6958

$stat . test
[1] 3.787229

$valori . soglia
[1] -1.959964 1.959964

```

\$pvalue
[1] 0.0001523364

\$Int.conf
[1] 491.9507 497.4408

In questo caso lo Z-test ci porta a rifiutare l'ipotesi nulla H_0 : il valore della statistica test pari a 3.787229 appartiene alla zona di rifiuto e il p -value è nettamente inferiore alla soglia fissata. Concludiamo che le lunghezze dei nati registrate nel campione sembrano essere, seppur di poco, significativamente diverse da quanto osservato nella popolazione.

3.4 Un test di indipendenza χ^2

In questa sezione cerchiamo di verificare l'ipotesi secondo cui, in alcuni parti ospedali, si facciano più parti cesarei. In questo caso siamo davanti a una tipologia di test statistico diverso da quelli visti finora che può essere formulato come segue.

3.4.1 Qualche cenno teorico

Dato un campione $X = \{x_1, \dots, x_n\}$ classificato in base alle modalità di due caratteri A e B , ci si pone il problema di validare o meno l'ipotesi di indipendenza dei due caratteri, in altre parole se la presenza di uno non influenzi l'altro all'interno del campione considerato. Pertanto si parte da una cosiddetta *tabella di contingenza* del tipo seguente:

	B_1	B_2	...	B_j	...	B_t	Totale
A_1	n_{11}	n_{12}	...	n_{1j}	...	n_{1t}	n_{10}
A_2	n_{21}	n_{22}	...	n_{2j}	...	n_{2t}	n_{20}
...	...	...	...	...	...	...	...
A_i	n_{i1}	n_{i2}	...	n_{ij}	...	n_{it}	n_{i0}
...	...	...	...	...	...	...	...
A_s	n_{s1}	n_{s2}	...	n_{sj}	...	n_{st}	n_{s0}
Totale	n_{01}	n_{02}	...	n_{0j}	...	n_{0t}	n

In particolare:

- il termine n_{ij} indica la frequenza assoluta delle unità campionarie che presentano la modalità A_i del carattere A e la modalità B_j del carattere B ;
- i termini n_{i0} e n_{0j} sono le *frequenze marginali* di A_i e B_j , definite rispettivamente come segue:

$$n_{i0} = n_{i1} + \dots + n_{it}, \quad n_{0j} = n_{1j} + \dots + n_{sj}.$$

A questa tabella di contingenza associamo la rispettiva *matrice probabilistica*

	B_1	B_2	...	B_j	...	B_t	Totale
A_1	p_{11}	p_{12}	...	p_{1j}	...	p_{1t}	p_{10}
A_2	p_{21}	p_{22}	...	p_{2j}	...	p_{2t}	p_{20}
...	...	...	...	...	...	...	...
A_i	p_{i1}	p_{i2}	...	p_{ij}	...	p_{it}	p_{i0}
...	...	...	...	...	...	...	...
A_s	p_{s1}	p_{s2}	...	p_{sj}	...	p_{st}	p_{s0}
Totale	p_{01}	p_{02}	...	p_{0j}	...	p_{0t}	1

dove $p_{ij} = \mathbb{P}(A_i \cap B_j)$, $p_{i0} = \mathbb{P}(A_i)$, $p_{0j} = \mathbb{P}(B_j)$ col vincolo che

$$p_{i0} = p_{i1} + \dots + p_{it}, \quad p_{0j} = p_{1j} + \dots + p_{sj}.$$

Il problema a cui ci si sottopone è quello di verificare l'indipendenza dei due caratteri A e B , ovvero se

$$\mathbb{P}(A_i \cap B_j) = \mathbb{P}(A_i)\mathbb{P}(B_j), \quad \forall i, j,$$

ovvero l'ipotesi nulla $H_0 : p_{ij} = p_{i0}p_{0j}, \quad \forall i, j$. Il test statistico può essere dunque riassunto come segue:

$$\begin{cases} H_0 : p_{ij} = p_{i0}p_{0j}, \quad \forall i, j \\ H_1 : \exists i, j \mid p_{ij} \neq p_{i0}p_{0j} \end{cases}$$

A tal proposito si considera la statistica test *chi quadrato*

$$\chi^2 = \sum_{i=1}^s \sum_{j=1}^t \frac{(n_{ij} - N)^2}{N}, \quad N = \frac{n_{i0}n_{0j}}{n},$$

e da noti risultati, sotto l'ipotesi vera di H_0 , si può dimostrare che

$$\chi^2 \sim \chi_{(s-1)(t-1)}^2,$$

dove $\chi_{(s-1)(t-1)}^2$ è una distribuzione χ^2 a $(s-1)(t-1)$ gradi di libertà. In particolare, fissando ad $\alpha \in (0, 1)$ un certo livello di significatività tale per cui

$$\mathbb{P}(\chi^2 \leq \chi_{1-\alpha}^2 \mid H_0) = 1 - \alpha,$$

definiamo la zona di rifiuto come $R = \{\chi^2 : \chi^2 > \chi_{1-\alpha}^2\}$, dove $\chi_{1-\alpha}^2$ è il rispettivo quantile della distribuzione $\chi_{(s-1)(t-1)}^2$.

3.4.2 Test in R

In accordo con quanto appena richiamato, cerchiamo di verificare l'ipotesi secondo cui, in alcuni parti ospedali, si facciano più parti cesarei. Stiamo considerando i caratteri (ovvero le variabili) *Ospedale* e *Tipo parto* che assumono le modalità *Nat* o *Ces* e *osp1*, *osp2* o *osp3* rispettivamente. Il seguente codice crea la tabella di contingenza:

```

data_chi2 = data_peso[c("Tipo.parto "," Ospedale")]

data_chi2_g <- data_chi2
  %>% group_by(Tipo.parto, Ospedale)
  %>% summarise(total_count=n(),.groups = 'drop')

tab1 = matrix(data=c(574,242,594,254,602,232), nrow=3, ncol=2, byrow=T)
colnames(tab1) = c("Nat","Ces")
row.names(tab1) = c("Osp1","Osp2", "Osp3")

#Output
> tab1
      Nat Ces
Osp1 574 242
Osp2 594 254
Osp3 602 232

```

Applicando il test χ^2 (nel nostro caso a 2 gradi di libertà avendo una tabella di contingenza 3×2) alla tabella di contingenza appena creata, tramite la function *chisq.test* si ottiene il seguente esito:

```

test.indip = chisq.test(tab1)
test.indip

#Output
> test.indip

      Pearson's Chi-squared test
data:  tab1
X-squared = 1.083, df = 2, p-value = 0.5819

```

Graficamente possiamo visualizzare la zona di rifiuto come segue:

```

plot(density(rchisq(100000, df=2)), xlim=c(0,8))
abline(v=qchisq(0.95, 2), col=2)
points(1.083, 0, cex=2, col=4)

```




Figura 8: Grafico della densità χ^2 a 2 gradi di libertà. In blu il valore della statistica $\chi^2 = 1.083$ che non è al di fuori della zona di rifiuto rappresentata dalla parte della retta reale a destra della retta rossa.

Considerando un livello di significatività pari a $\alpha = 0.05$, abbiamo $0.05 < p\text{-value}$. Siamo dunque portati a non rifiutare H_0 e quindi di ritenere significativa l'ipotesi di indipendenza: la scelta di adottare una tipologia di parto non dipende dall'ospedale considerato.

4 Analisi multidimensionale

In questa sezione proviamo a elaborare un modello di regressione lineare multipla tra la variabile risposta *Peso* rispetto a tutte le altre, dette *descrittori*. Per la costruzione del modello adotteremo la *lm procedure* di R; non essendo tutti i descrittori quantità numeriche, tale procedura traduce in automatico in flag numerici i descrittori che non lo sono. Nella sezione che segue iniziamo a studiare possibili relazioni a due a due delle variabili tramite una matrice di correlazione.

4.1 Relazioni a due a due

Indicando con $S(\mathbb{R}^n)$ l'insieme delle matrici reali simmetriche, il seguente codice costruisce una matrice di correlazione $M \in S(\mathbb{R}^n)$ per le variabili quantitative specificate nella lista *quantitative*. Per plottare la matrice si è utilizzati il comando *corrplot* della library *corrplot*. L'option *number* consente di visualizzare in output il coefficiente di correlazione lineare tra due variabili X_i e X_j , definito dalla formula

$$M_{ij} = \rho_{X_i X_j} = \frac{\sigma_{X_i X_j}}{\sigma_{X_i} \sigma_{X_j}},$$

dove $\sigma_{X_i X_j}$ e σ_{X_i} sono le rispettive covarianze e deviazioni standard delle variabili in gioco:

$$\sigma_{X_i X_j} = \frac{1}{n} \sum_{k=1}^n (X_i^k - \bar{X}_i)(X_j^k - \bar{X}_j),$$

$$\sigma_{X_i} = \sqrt{\frac{1}{n} \sum_{k=1}^n (X_i^k - \bar{X}_i)^2}.$$

Ricordando che $\rho_{X_i X_j} \in [-1, 1]$, avremo una correlazione positiva più il valore del coefficiente tende a 1 mentre una correlazione negativa più il valore tende a -1. Di seguito il codice utilizzato per la costruzione della matrice. Dall'output sembra interessante plottare le relazioni tra la variabile *Peso* rispetto i descrittori *Lunghezza*, *Cranio* e *Gestazione*. Il codice prosegue con la costruzione di vari scatterplot sulle variabili specificate:

```
library (ggplot2)
library (dplyr)

quantitative <- c("Anni.madre",
                  "Peso",
                  "N.settimane ",
                  "Lunghezza",
                  "Cranio",
```

```

"N.gravidanze",
"Gestazione")

quantiv_data <- data_peso[ quantitative ]

# Correlation matrix
library ( corrplot )
M = cor( quantiv_data )
print ( corrplot (M, method="number"))

# Scatterplot
attach ( quantiv_data )
plot (Peso, Gestazione, pch=20, col=4)
grid(nx = NULL, ny = NULL, lty = 3, col = "gray", lwd = 2)

```




Figura 9: Matrice di correlazione per le variabili quantitative. Notiamo come la variabile risposta *Peso* sia fortemente correlata alle variabili *Lunghezza* e *Cranio*. A queste si aggiunge anche la variabile *Gestazione* con un coefficiente di correlazione pari a 0.59. A giudicare dagli scatterplot, sarebbe interessante tenere in considerazione degli effetti non lineari sulle variabili *Lunghezza*, *Cranio* e *N.gravidanze*. Si potrebbero testare degli effetti di tipo potenza o logaritmici a giudicare dai trend in rosso. Avremo modo di approfondire la questione nella sezione successiva sulla costruzione dei modelli.




Figura 10: Vari scatterplot: i plot (a), (b) e (c) riguardano le relazioni tra la variabile risposta *Peso* con quelle indicate in sottotitolo. Risulta pertanto evidente considerare questi tre descrittori nella costruzione del modello e sperimentare con delle interazioni quadratiche a giudicare dalla disposizione grafica. Il plot (d) invece rende evidente anche una relazione lineare positiva tra le dimensioni del cranio con la lunghezza alla nascita del nascituro.

4.2 Un modello di regressione multipla

In questa sezione cerchiamo di creare un modello di regressione lineare multipla seguendo la metodologia dei minimi quadrati. Per adesso iniziamo a tenere conto di tutti i descrittori per poi applicare una metodologia stepwise in modo da determinare un modello migliore tra tutti quelli analizzati. In particolare, indicando con Y la variabile risposta *Peso* e con $\{X_i\}_{i=1\dots 9}$ i descrittori, matematicamente cerchiamo di determinare opportuni coefficienti beta $\beta_0, \beta_1, \dots, \beta_9 \in \mathbb{R}$ tali per cui, vettorialmente, si ha

$$Y = \beta_0 + \sum_{i=1}^9 \beta_i X_i + \varepsilon \in \mathbb{R}^n,$$

dove ε è un'opportuna parte erratica, che tiene conto degli errori non gestibili dal modello. Indicando con Y^j la j -esima componente del vettore Y , la costruzione dei parametri beta tiene conto della tecnica dei minimi quadrati ovvero indicando con f la funzione degli scarti quadratici

$$f(\beta_0, \beta_1, \dots, \beta_9) := \sum_{j=1}^n (Y^j - \hat{Y}^j)^2 = \sum_{j=1}^n \left(\beta_0 + \sum_{i=1}^9 \beta_i X_i^j + \varepsilon^j - \hat{Y}^j \right)^2,$$

si cerca di determinare $(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_9)$ per cui:

$$\min_{(\beta_0, \beta_1, \dots, \beta_9)} f(\beta_0, \beta_1, \dots, \beta_9) = f(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_9).$$

Per quanto riguarda la componente erratica $\{\varepsilon^j\}_{j=1\dots n}$, assumeremo inoltre le seguenti ipotesi di lavoro:

- i valori $\{\varepsilon^j\}_{j=1\dots n}$ sono indipendenti gli uni dagli altri;
- i valori $\{\varepsilon^j\}_{j=1\dots n}$ hanno tutti media 0 e varianza uguale (quest'ultima viene detta *omoschedasticità*);
- i valori $\{\varepsilon^j\}_{j=1\dots n}$ seguono una distribuzione normale.

Dal punto di vista teorico, una metodologia per verificare la verosomiglianza che tali ipotesi siano soddisfatte consiste nella verifica di tali ipotesi sui residui.

4.3 Un primo modello

Per la costruzione del primo modello applichiamo la *lm procedure* che, presi in input le variabili del modello e il dataset da cui prelevarle, determina la stima dei coefficienti beta. Si è inoltre riportato il rispettivo output che a breve commenteremo:

```
#mod1: lm procedure
mod1 = lm(Peso ~ Anni.madre +
          N.gravidanze +
          Fumatrici +
          Gestazione +
          Lunghezza +
          Cranio +
          Tipo.parto + Ospedale +
          Sesso, data=data_peso)

summary(mod1)
```

#Output
Coefficients :

	Estimate	Std. Error	t-value	Pr(> t)
(Intercept)	-6735.7960	141.4790	-47.610	< 2e-16 ***
Anni.madre	0.8018	1.1467	0.699	0.4845
N.gravidanze	11.3812	4.6686	2.438	0.0148 *
Fumatrici	-30.2741	27.5492	-1.099	0.2719
Gestazione	32.5773	3.8208	8.526	< 2e-16 ***
Lunghezza	10.2922	0.3009	34.207	< 2e-16 ***
Cranio	10.4722	0.4263	24.567	< 2e-16 ***
Tipo.partoNat	29.6335	12.0905	2.451	0.0143 *
Ospedaleosp2	-11.0912	13.4471	-0.825	0.4096
Ospedaleosp3	28.2495	13.5054	2.092	0.0366 *
SessoM	77.5723	11.1865	6.934	5.18e-12 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 274 on 2487 degrees of freedom
Multiple R-squared: 0.7289, Adjusted R-squared: 0.7278
F-statistic: 668.7 on 10 and 2487 DF, p-value: < 2.2e-16

Osserviamo che la quantità $Pr(>|t|)$ esprime la probabilità che l'*i*-esimo coefficiente β_i associato alla rispettiva variabile X_i sia uguale a 0. Pertanto, più tale probabilità

tende a 0, più β_i è diverso da zero. Forti di questa considerazione, si sarà più propensi a non scartare il rispettivo descrittore all'interno del modello.

Per la bontà di adattamento, possiamo utilizzare gli indicatori R^2 e R^2_{adj} : più questi tendono ad 1, maggiore è la bontà di adattamento in base ai coefficienti beta considerati. In particolare, propenderemo all'indicatore R^2_{adj} , una versione più robusta dell'indicatore R^2 .

In questo primo modello possiamo osservare che l' R^2_{adj} è pari a 0.7278 il che ci dice che il modello tende ad approssimare in modo abbastanza buono. Possiamo anche osservare che le variabili *Gestazione*, *Lunghezza*, *Cranio* e *SessoM* sono sicuramente da tenere in considerazione, essendo la loro $Pr(> |t|)$ quasi nulla. Per le altre variabili si potrebbe sperimentare tenendole o togliendole durante la procedura stepwise di selezione del modello. Nella sezione che segue proviamo ad applicare tale procedura per individuare il modello migliore; in base anche alla Figura 9, valuteremo anche l'ipotesi di inserire qualche interazione non lineare.

4.4 Scelta del modello migliore

Nella sezione che segue riportiamo altri modelli costruiti tramite la *lm procedure*. In accordo con quanto osservato in Figura 9, in alcuni di questi si è sperimentato considerando effetti non lineari.

```
mod2 = lm(Peso ~ N.gravidanze + Gestazione + Lunghezza + Cranio + Sesso,
          data = data_peso)
summary(mod2)

mod3 = lm(Peso ~ N.gravidanze + Gestazione + Lunghezza + I(Cranio^2) + Sesso,
          data = data_peso)
summary(mod3)

mod4 = lm(Peso ~ N.gravidanze + Gestazione + Lunghezza:Cranio + Sesso,
          data = data_peso)
summary(mod4)

mod5 = lm(Peso ~ N.gravidanze + Gestazione + log(Lunghezza) + log(Cranio) + Sesso,
          data = data_peso)
summary(mod5)

mod6 = lm(Peso ~ Gestazione + Lunghezza + Cranio + Sesso,
          data = data_peso)
summary(mod6)
```

Di seguito un elenco degli R^2 e dei R^2_{adj} di ogni modello, compreso il *mod1* già visionato:

Modello	R^2	R^2_{adj}
mod1	0.7289	0.7278
mod2	0.727	0.7265
mod3	0.7287	0.7281
mod4	0.7257	0.7253
mod5	0.7144	0.7139
mod6	0.7261	0.7257

Possiamo notare che tutti i modelli tendono in media a una bontà di adattamento poco al di sopra del 70%. In particolare, il *mod3* è quello con l' R^2_{adj} maggiore. Come ulteriore test per la scelta del modello più performante, qui di seguito riportiamo il test *BIC* (*Bayesian Information Criterion*):

```
BIC(mod1, mod2, mod3, mod4, mod5, mod6)
```

```
#Output
> BIC(mod1, mod2, mod3, mod4, mod5, mod6)
      df      BIC
mod1 12 35215.45
mod2  7 35193.65
mod3  7 35178.45
mod4  6 35197.75
mod5  7 35306.12
mod6  6 35194.06
```

Il *mod3* risulta essere il modello più performante anche secondo il *BIC* criterion, che predilige quei modelli con indicatore *BIC* minore. Del resto, notiamo differenze numeriche in modulo al di sotto dell'1% tra i vari indicatori *BIC*: considerando anche i costi computazionali di un effetto quadratico e ricordando il noto principio di Occam, optiamo a considerare il *mod6*, che tiene conto di sole quattro variabili, ritenute interessanti anche in fase di analisi descrittiva. Qui di seguito riportiamo il valore dei coefficienti beta del *mod6*:

```
Coefficients :
      Estimate Std. Error t value Pr(>|t|)
( Intercept ) -6651.6732   135.5952 -49.055 < 2e-16 ***
Gestazione     31.3262     3.7884   8.269 < 2e-16 ***
Lunghezza     10.2024     0.3009  33.909 < 2e-16 ***
Cranio         10.6706     0.4247  25.126 < 2e-16 ***
SessoM        79.1027    11.2205   7.050 2.31e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 275.1 on 2493 degrees of freedom
Multiple R-squared:  0.7261, Adjusted R-squared:  0.7257
F-statistic : 1652 on 4 and 2493 DF, p-value: < 2.2e-16
```

Ricordando che il generico *VIF* del coefficiente dell'*i*-esimo regressore indica quanto tale coefficiente sia influenzato dalle stime degli altri, possiamo anche osservare che tutti i *VIF* sono minori di 5, segno della non presenza di multicollinearità:

```
> car::vif(mod6)
Gestazione Lunghezza Cranio Sesso
1.654101    2.070582    1.606316    1.038918
```

4.5 Il Mod6: analisi dei coefficienti

Il modello *mod6* può essere riscritto come

$$P = -6651.6732 + 31.3262 G + 10.2024 L + 10.6706 C + 79.1027 \mathbb{I}_M,$$

dove:

- P è la variabile *Peso*, la variabile risposta. Al momento della nascita, possiamo stimare il peso tenendo conto delle misurazioni dei regressori G , L , C e $\mathbb{I}_M$;

- G è la variabile *Gestazione*, con coefficiente beta pari a 31.3262. Questo implica che (tenendo fissate le altre variabili) per ogni settimana di gestazione, la massa del neonato aumenta di circa 31.30 grammi in più;
- L è la variabile *Lunghezza*, con coefficiente beta pari a 10.2024; questo implica che (tenendo fissate le altre variabili) per ogni millimetro di lunghezza, la massa del neonato aumenta di circa 10.20 grammi in più;
- C è la variabile *Cranio*, con coefficiente beta pari a 10.6706; questo implica che (tenendo fissate le altre variabili) per ogni millimetro di lunghezza del diametro, la massa del neonato aumenta di circa 10.60 grammi in più;
- dato che R traduce di default le variabili dummy, la variabile *Sesso* è stata indicata con la funzione indicatrice $\mathbb{I}_M$ che è uguale a 1 nel caso di $Sesso = M$ e 0 nel caso $Sesso = F$. Pertanto, nei maschi (tenendo fissate le altre variabili), si rileva un aumento di massa del neonato di circa 79.10 grammi in più rispetto a quello delle femmine.

4.5.1 Analisi dei residui: mod6

In questa sezione effettuiamo un'analisi sui residui del *mod6* come analisi preliminare della bontà del modello. Il comando `par(mfrow=c(2,2))` seguito da `plot(mod6)` effettua l'output seguente:




Figura 11: Analisi dei residui del *mod6*. In alto a sinistra possiamo notare come i residui si concentrino intorno allo 0. In alto a destra il Q-Q-plot mette in relazione i quantili della normale con quelli dei residui standardizzati: questi si dispongono lungo la retta eccetto per alcuni valori delle code. Tale Q-Q-plot è un buon indicatore del fatto che i residui si distribuiscono seguendo una distribuzione normale. Il grafico in basso a sinistra riguarda invece la varianza dei residui, che sembra mantenersi costante. L'ultimo grafico in basso a destra riguarda lo studio dei leverages: tra questi sembra emergere un'osservazione che supera la soglia di 0.50 per la distanza di Cook. Avremo modo di approfondire questo aspetto in seguito.

Oltre all'analisi grafica, per la verifica di omoschedasticità dei residui, possiamo effettuare un test di Breusch-Pagan (*bptest*) mentre per la verifica di normalità possiamo applicare un test di Shapiro-Wilk (*shapiro.test*):

```
%#bptest & shapirotest
lmtest :: bptest(mod6)
shapiro.test(mod6$residuals)
plot(density(residuals(mod6)))

#Output Breusch-Pagan Test
> lmtest :: bptest(mod6)
      studentized Breusch-Pagan test
data:  mod6
BP = 89.198, df = 4, p-value < 2.2e-16

#Output Shapiro Test
> shapiro.test(mod6$residuals)
      Shapiro-Wilk normality test
data:  mod6$residuals
W = 0.97426, p-value < 2.2e-16
```

Osserviamo che la *shapiro.test* sembra escludere l'ipotesi di normalità essendo il *p-value* < 0.05 . Del resto, una rappresentazione grafica della densità dei residui di Figura 12, ci permette di osservare una distribuzione che ricorda una normale: essendo il test di Shapiro molto sensibile, questa discordanza è dovuta, con molta probabilità, alle code leggermente aperte del QQ-plot, osservabili in Figura 11, assieme alla presenza di osservazioni anomale, come la 1549. Considerazioni analoghe sono osservabili anche per il *bptest*. Ricordiamo comunque che il *mod6* ha un buon adattamento, con un indicatore R^2_{adj} del 72% circa: terremo a mente queste considerazioni sui residui senza però nulla togliere alla bontà del *mod6*.




Figura 12: Output del comando `plot(density(residuals(mod6)))`: i residui sembrano distribuirsi secondo una normale centrata in 0.

4.5.2 Valori anomali: outliers e leverages del *mod6*

Ricordiamo che con *valore anomalo* si intende un'osservazione che presenta caratteristiche inusuali dal resto dei dati. Per comodità di notazione, sia (x_i, y_i) una generica osservazione (descrittore e rispettiva variabile risposta). Questa viene detta anomala se:

- tra le unità che presentano lo stesso valore della variabile esplicativa, l'unità in esame presenta un valore della variabile risposta molto diverso;
- il valore della variabile esplicativa, x_i è isolato dal resto dei valori della variabile esplicativa osservati.

In particolare possiamo ridefinire i due punti seguenti come segue:

- *outliers*: è un'osservazione con un valore estremo della variabile dipendente (variabile risposta). Questo implica spesso un residuo elevato. Una metodologia per la loro determinazione consiste nello stabilire quelle osservazioni con residui standardizzati (function *rstandard*) o studentizzati (function *rstudent*) elevati sopra una certa soglia;
- *leverages*: è un'osservazione con un valore della variabile indipendente lontano dalla media (in dimensione $p = 1$ ma un discorso analogo vale per $p > 1$). Una metodologia per la loro determinazione consiste nello stabilire quelle osservazioni con valori delle variabili esplicative distanti dalle rispettive medie. In particolare, il *leveraggio* $H_{ii} \in [0, 1]$ misura l'influenza di y_i sulla previsione $\hat{y}_i$ e possiamo definirlo in modo che

$$\hat{y}_i = \sum_{j=1}^n H_{ij} y_j.$$

Spesso si adotta il vincolo $\sum_{i=1}^n H_{ii} = p + 1$, pertanto essendo la media dei leveraggi pari a $\frac{p+1}{n}$ si adotta spesso come soglia il valore $\frac{2(p+1)}{n}$.

Osservazioni con un comportamento anomalo potrebbero influenzare le approssimazioni del modello e saranno da ritenere influenti se la loro rimozione comporta un cambiamento notevole nelle stime dei parametri o degli indicatori R^2 e R_{adj}^2 . Precisiamo inoltre che la presenza di outliers o leverages non implica per forza un'influenza sui dati. Questa prima porzione di codice mette in luce eventuali outliers:

```
plot ( rstudent (mod6))  
abline (h=c(-2, 2), col=2)  
car :: outlierTest (mod6)
```




Figura 13: Outliers del *mod6*: in rosso l'intervallo di soglia, spesso fissato a (-2,2). Per ognuna delle 2498 osservazioni (variabile *index*) viene calcolato il residuo studentizzato.

Otteniamo in output tre valori considerabili come outlier che sono da considerarsi potenzialmente influenti sulle stime:

```
> car :: outlierTest (mod6)
      rstudent unadjusted p-value Bonferroni p
1549 9.980701      4.9791e-23  1.2438e-19
155  4.948947      7.9596e-07  1.9883e-03
1305 4.779033      1.8638e-06  4.6558e-03
```

Veniamo ora allo studio di eventuali leverages tramite la function *hatvalues*:

```
par(mfrow=c(2,1))
lev = hatvalues(mod6)
plot(lev)
p = sum(lev)
n = length(lev)
soglia = 2*(p+1)/n
abline(h=soglia, col=2)
plot(lev[lev>soglia])
```




Figura 14: Studio dei leverages del modello *mod6*: a destra i leverages al di sopra del valore di soglia rappresentato dalla retta rossa del grafico a sinistra. Tramite il comando `length(lev[lev>soglia])`, ne individuiamo 84. Questo per ora non implica che siano valori influenti al modello.

In modo equivalente alle due analisi appena svolte, avremmo potuto utilizzare un controllo tramite la distanza di Cook per determinare eventuali valori anomali. In particolare, la distanza di Cook misura il cambiamento di ogni valore previsto $\hat{y}^i$ (*fitted value*) quando l'*i*-esima osservazione viene rimossa dal set di dati usato per la stima del modello. Questa metrica viene formalmente costruita come segue: per l'*i*-esima osservazione definiamo tale distanza come

$$D_i = \frac{\sum_{j=1}^n (\hat{y}^j - \hat{y}^{j(i)})^2}{ps^2},$$

dove $\hat{y}^{j(i)}$ è la risposta ottenuta escludendo l'*i*-esima osservazione mentre s^2 è l'*MSE* del modello (*Mean Square Error*). La soglia per individuare osservazioni influenti è spesso fissata a 1. Di seguito il codice adottato:

```

cook = cooks.distance(mod6)
plot(cook)
abline(h=1, col="red", lwd=2)
max(cook)

```




Figura 15: Plot della distanza di Cook: per ognuna delle 2498 osservazioni (variabile *index*) viene calcolata tale metrica. Notiamo che tutti i valori sono minori di 1.

Dal grafico di Figura 15 sembra esserci una osservazione con distanza maggiore di 0.50, quasi prossima alla soglia critica. Per individuarla eseguiamo il seguente filtro ottenendo un unico output:

```

cook_filter = data.frame(cook)
head( cook_filter )
cook_filter2 = cook_filter %>% filter (cook > 0.5)
cook_filter2

#Output
> cook_filter2
      cook
1549 0.9780498

```

L'osservazione incriminata è la 1549, già osservata in Figura 11 (nel grafico globale dei residui) e nell'output della *outliersTest* function. Nella sezione che segue proviamo a eliminarla dal dataset col fine di studiare eventuali impatti sul modello.

4.6 Rimozione di eventuali valori anomali: mod1549

In questa sezione proviamo a ricostruire il modello *mod6* eliminando dal dataset anche l'osservazione 1549. Chiameremo questo nuovo modello come *mod1549*:

```

data_pesoF = data_peso[-c(1549),]# Rimozione osservazione 1549
data_pesoF

mod1549 = lm(Peso ~ Gestazione + Lunghezza + Cranio + Sesso,
             data = data_pesoF)
summary(mod1549)

```

Con la rimozione del record incriminato, otteniamo un nuovo modello con un R^2_{adj} pari a 0.7358, maggiore di quello del *mod6*. I coefficienti beta rimangono sempre rilevanti.

Coefficients :

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-6652.115	132.990	-50.020	< 2e-16 ***
Gestazione	28.533	3.726	7.657	2.69e-14 ***
Lunghezza	10.841	0.302	35.903	< 2e-16 ***
Cranio	10.059	0.421	23.893	< 2e-16 ***
SessoM	79.321	11.005	7.208	7.51e-13 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 269.8 on 2492 degrees of freedom

Multiple R-squared: 0.7362, Adjusted R-squared: 0.7358

F- statistic : 1739 on 4 and 2492 DF, p-value: < 2.2e-16

Di seguito lo studio dei residui e il calcolo della distanza di Cook applicando quanto già visto nella sezione precedente:

```
#Plot dei residui
par(mfrow=c(2,2))
plot(mod1549)

#Cook distance
cook = cooks.distance(mod1549)
plot(cook)
abline(h=1, col="red", lwd=2)
max(cook)
```




Figura 16: Studio dei residui del *mod1549*: in modo simile all'analisi svolta in Figura 11, notiamo sempre un buon adattamento del modello. Nel grafico in basso a destra non appare più l'osservazione 1549 che superava la soglia di Cook di 0.50.




Figura 17: Studio della distanza di Cook per il *mod1549*. Osserviamo che non abbiamo più valori prossimi alla soglia critica di 1.

4.6.1 Il *mod1549*: analisi dei coefficienti

Il modello *mod1549* può essere riscritto come

$$P = -6652.115 + 28.533 G + 10.841 L + 10.059 C + 79.321 \mathbb{I}_M,$$

dove:

- P è la variabile *Peso*, la variabile risposta. Al momento della nascita, possiamo stimare il peso tenendo conto delle misurazioni dei regressori G , L , C e $\mathbb{I}_M$;
- G è la variabile *Gestazione*, con coefficiente beta pari a 28.533. Questo implica che (tenendo fissate le altre variabili) per ogni settimana di gestazione, la massa del neonato aumenta di circa 28.50 grammi in più;
- L è la variabile *Lunghezza*, con coefficiente beta pari a 10.841; questo implica che (tenendo fissate le altre variabili) per ogni millimetro di lunghezza, la massa del neonato aumenta di circa 10.80 grammi in più;
- C è la variabile *Cranio*, con coefficiente beta pari a 10.059; questo implica che (tenendo fissate le altre variabili) per ogni millimetro di lunghezza del diametro, la massa del neonato aumenta di circa 10.05 grammi in più;
- dato che R traduce di default le variabili dummy, la variabile *Sesso* è stata indicata con la funzione indicatrice $\mathbb{I}_M$ che è uguale a 1 nel caso di $Sesso = M$ e 0 nel caso $Sesso = F$. Pertanto, nei maschi (tenendo fissate le altre variabili), si rileva un aumento di massa del neonato di circa 79.30 grammi in più rispetto a quello delle femmine.

4.6.2 Metriche RMSE e MAE

In questa sezione introduciamo il calcolo di alcune metriche tipiche per stimare l'errore di misurazione del modello *mod1549* rispetto al dataset su cui è stato costruito. Il seguente codice esegue una stima del *RMSE* (*Root Mean Square Error*) e del *MAE* (*Mean Absolute Error*) definite come

$$RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^N (Y^j - \hat{Y}^j)^2}, \quad MAE = \frac{1}{n} \sum_{j=1}^N |Y^j - \hat{Y}^j|,$$

dove $N = 2497$, Y^j è l' j -esima osservazione della variabile *Peso* del dataset mentre $\hat{Y}^j$ è il valore stimato della variabile *Peso* tramite il modello *mod1549* calcolato sui dati del dataset. Di seguito il codice:

```
prediction = predict(mod1549, newdata = data_pesoF)

data <- data.frame(pred = prediction, actual = data_pesoF$Peso)
head(data)

MAE = mean(abs(data$actual - data$pred))
MAE

RMSE = sqrt(mean((data$actual - data$pred)^2))
RMSE
```

Qui di seguito alcune stime tramite la *predict* function estratte tramite la *head* function, il calcolo dell'*RMSE* e del *MAE* scritte manualmente:

```
> data <- data.frame(pred = prediction, actual = data_peso$Peso)
> head(data)
  pred actual
1 3207.023  3380
2 3243.285  3150
3 3704.259  3640
4 3851.886  3690
5 3005.749  3700
6 3275.729  3200

> RMSE = sqrt(mean((data$actual - data$pred)^2))
> RMSE
[1] 269.5399

> MAE = mean(abs(data$actual - data$pred))
> MAE
[1] 210.0954
```

Possiamo dunque concludere che il modello *mod1549*, in termini predittivi della variabile *Peso*, potrebbe sbagliare di una soglia compresa tra i 200 e i 300 grammi.

5 Analisi grafica: mod1549

Di seguito alcuni grafici ottenuti tramite le seguenti linee di codice:

```
library (rgl)
library (car)
scatter3d (data_pesoF$mod1549 ~ data_pesoF$Lunghezza + data_pesoF$Cranio, data_pesoF,
           surface . alpha=0.5)
```




Figura 18: Alcune sezioni dell'iperpiano multidimensionale del modello, in linea con il segno positivo dei coefficienti descrittivi.




Figura 19: Sezione tridimensionale del modello *mod1549* mettendo in relazione il peso ottenuto dal fitting rispetto ai descrittori *Lunghezza* e *Cranio*.

5.1 Un quesito di stima del mod1

In questa sezione approfondiamo la seguente richiesta: senza sapere nessuna misurazione da un'eventuale ecografia, si chiede di effettuare la migliore previsione (tramite il *mod1*) per il peso di una neonata, considerato che la madre è alla terza gravidanza e che partorirà alla 39esima settimana. Per stimare i valori mancanti delle variabili *Lunghezza* e *Cranio* usiamo le medie estratte dal dataset:

```
summary(data_peso)
```

Pertanto, tramite il *mod1* visto nella Sezione 4.3, possiamo stimare il peso come

$$\begin{aligned} P = & -6735.7960 + 0.8018 \cdot 28 + 11.3812 \cdot 3 - 30.2741 \cdot \mathbb{I}_F + 32.5773 \cdot 39 \\ & + 10.2922 \cdot 494.70 + 10.4722 \cdot 340 + 29.6335 \cdot \mathbb{I}_{nat} - 11.0912 \cdot \mathbb{I}_{osp2} \\ & + 28.2495 \cdot \mathbb{I}_{osp3} + 77.5723 \cdot \mathbb{I}_M, \end{aligned}$$

dove $\mathbb{I}_F$, $\mathbb{I}_{nat}$, $\mathbb{I}_{osp2}$, $\mathbb{I}_{osp3}$, $\mathbb{I}_M$ sono rispettivamente le funzioni indicatrici delle variabili dummy *Fumatrici*, *PartoNaturale*, *Ospedale2*, *Ospedale3*, *Maschio*. Ad esempio, supponendo che la madre abbia partorito nel primo ospedale con taglio cesareo e che non sia fumatrice, segue che

$$\begin{aligned} P = & -6735.7960 + 0.8018 \cdot 28 + 11.3812 \cdot 3 + 32.5773 \cdot 39 \\ & + 10.2922 \cdot 494.70 + 10.4722 \cdot 340 \sim 3243,41204, \end{aligned}$$

ovvero possiamo approssimare il peso a circa 3.2 chili.

6 Conclusioni

In queste pagine si è giunti a esplorare vari modelli di regressione lineare multipla sfruttando la metodologia dei minimi quadrati; tra questi, si è individuato il *mod1549* descritto dalla formula

$$P = -6652.115 + 28.533 G + 10.841 L + 10.059 C + 79.321 \mathbb{I}_M,$$

approfondita nella Sezione 4.6.1. L'analisi delle metriche *RMSE* e *MAE* ha portato a un errore predittivo tra i 200 e i 300 grammi per la variabile *Peso*. Per la costruzione di questo modello si è assunta la metodologia dei minimi quadrati, la rimozione di due record per cui l'età della madre risultava pari a 0 e a 1 e l'eliminazione di un'osservazione anomala (record 1549) che ha portato a un leggero miglioramento dell' R_{adj}^2 . Sarebbe interessante effettuare ulteriori approfondimenti nel considerare anche l'effetto della variabile *Fumatrici*, variabile non considerata essendo l' R_{adj}^2 risultato molto basso nei modelli in cui tale variabile era stata aggiunta.

Riferimenti bibliografici

- [1] P. Baldi, *Introduzione alla probabilità con strumenti di statistica*, McGraw-Hill, 2012.
- [2] A. Pascucci, *Calcolo stocastico per la finanza*, Springer, 2008.
- [3] G. Cicchitelli, P. D'Urso, M. Minozzo, *Statistica: principi e metodi*, Pearson, 2017.
- [4] W. Navidi, *Probabilità e statistica per l'ingegneria e le scienze*, McGraw-Hill, 2006.