

Analisi delle vendite del mercato immobiliare texano

Matteo M. Costa

20 Febbraio 2024

1 Data exploring

In questa sezione iniziamo a esplorare il dataset *realestate_texas.csv* che può essere importato tramite la function *read.csv*. Tramite le function *dim* o *str* possiamo estrarre informazioni relative alla dimensione del dataset e al tipo di variabili contenute:

```
#Import csv
data_texas = read.csv("C:\\Users\\Costa\\Desktop\\MASTER\\realestate_texas.csv")

#Exploring data
str ( data_texas )
```

In particolare il dataset è costituito da 8 variabili e 240 record. Le variabili sono qui di seguito riportate:

- *city*: nome della città
- *year*: anno di riferimento
- *month*: mese di riferimento
- *sales*: numero tot. di vendite
- *volume*: valore tot. delle vendite in milioni di dollari
- *median_price*: prezzo mediano di vendita in dollari
- *listings*: numero totale di annunci attivi
- *month_inventory*: quantità di tempo necessaria per vendere tutte le inserzioni correnti al ritmo attuale delle vendite, espresso in mesi

1.1 Tipologia di variabili

Possiamo classificare le variabili del dataset come segue:

- qualitative nominali: *city*
- qualitative ordinali: *year*, *month*
- quantitative continue: *sales*, *volume*, *median_price*, *listings*, *month_inventory*

1.2 Analisi e indici statistici

Possiamo iniziare a effettuare uno studio sulla variabile *city* per avere un'idea delle città presenti nel dataset. Il comando *table* consente di effettuare una prima sintesi sulla distribuzione delle frequenze assolute:

```
table ( data_texas$city )
```

In particolare possiamo osservare che abbiamo sessanta immobili registrati per ognuna delle quattro città presenti:

- Beaumont: 60
- Bryan-College Station: 60
- Tyler 60:
- Wichita Falls: 60

Più in generale, per analizzare la distribuzione delle frequenze (assolute, relative e rispettive cumulate) della variabile *city* e delle variabili *year* e *month*, si è creata la function *freq_analysis* che prendendo in input un dataframe e la rispettiva colonna ne restituisce una tabella di frequenze:

```
freq_analysis = function (df, col){  
  absfreq = table (df [[ col ]])  
  relfreq = absfreq / dim(df)[1]  
  absfreqsum = cumsum(absfreq)  
  relfreqcum = cumsum(relfreq)  
  freq_rep = cbind( absfreq , relfreq , absfreqsum, relfreqcum)  
  return ( freq_rep )  
}  
  
freq_analysis ( data_texas , " city ")  
freq_analysis ( data_texas , "year")  
freq_analysis ( data_texas , "month")
```

In particolare, per le variabili *city*, *year* e *month* abbiamo i seguenti output:

	absfreq	relfreq	absfreqsum	relfreqcum
Beaumont	60	0.25	60	0.25
Bryan-College Station	60	0.25	120	0.50
Tyler	60	0.25	180	0.75
Wichita Falls	60	0.25	240	1.00

	absfreq	relfreq	absfreqsum	relfreqcum
2010	48	0.2	48	0.2
2011	48	0.2	96	0.4
2012	48	0.2	144	0.6
2013	48	0.2	192	0.8
2014	48	0.2	240	1.0

	absfreq	relfreq	absfreqsum	relfreqcum
1	20	0.08333333	20	0.08333333
2	20	0.08333333	40	0.16666667
3	20	0.08333333	60	0.25000000
4	20	0.08333333	80	0.33333333
5	20	0.08333333	100	0.41666667
6	20	0.08333333	120	0.50000000
7	20	0.08333333	140	0.58333333
8	20	0.08333333	160	0.66666667
9	20	0.08333333	180	0.75000000
10	20	0.08333333	200	0.83333333
11	20	0.08333333	220	0.91666667
12	20	0.08333333	240	1.00000000

Per l'analisi delle variabili quantitative continue, si sono utilizzate le function *pos_index* e *var_index* qui di seguito riportate. Entrambe le funzioni prendono in input un dataset sul quale ciclano sulle rispettive colonne in modo da prendere le informazioni necessarie per il calcolo dei vari indici statistici che verranno poi stampati in output su un dataframe creato appositamente (dataframe *measurements*):

```
library ( dplyr )
quantitative <- c(" sales "," volume","median_price"," listings "," months_inventory")
quantiv_data <- data_texas [ quantitative ]

pos_index = function (df){
  measurements = data.frame( attributes = character (),
                             mean = double (),
                             median = double ()
                             )

  for ( i in 1:ncol(df)){
    names = colnames(df)[ i ]
    pos_temp = data.frame( attribute = names,
                          mean = round(mean(df[, i ]), digits =2),
```

```

        median = round(median(df[, i ]), digits =2)
    )
    measurements = rbind(measurements, pos_temp)
}
return (measurements)
}

var_index = function(df){
  measurements = data.frame( attributes = character (),
                              range = double (),
                              IQR = double (),
                              variance = double (),
                              sd = double (),
                              cv = double()# Variable with bigger variability
                              )

  for (i in 1:ncol(df)){
    names = colnames(df)[ i ]
    var_temp = data.frame( attribute = names,
                          range = round(max(df[, i ]) - min(df[, i ]), digits =2),
                          IQR = round(IQR(df[, i ]), digits =2),
                          var = round(var(df[, i ]), digits =2),
                          sd = round(sd(df[, i ]), digits =2),
                          cv = round((sd(df[, i ])/ mean(df[, i ]))*100, digits =2)
                          )

    measurements = rbind(measurements, var_temp)
  }
  return (measurements)
}

pos_index(quantiv_data)
var_index(quantiv_data)

```

Si ottengono i seguenti indici di posizione e di variabilità:

attribute	mean	median
sales	192.29	175.50
volume	31.01	27.06
median_price	132665.42	134500.00
listings	1738.02	1618.50
months_inventory	9.19	8.95

attribute	range	IQR	var	sd	cv
sales	344.00	120.00	6.34430e+03	79.65	41.42
volume	75.38	23.23	2.77270e+02	16.65	53.71
median_price	106200.00	32750.00	5.13573e+08	22662.15	17.08
listings	2553.00	1029.50	5.66569e+05	752.71	43.31
months_inventory	11.50	3.15	5.31000e+00	2.30	25.06

La colonna *cv* dell'ultima tabella rappresenta il coefficiente di variazione implementato secondo la formula

$$cv = \frac{\sigma}{\bar{x}} 100.$$

Possiamo notare che il valore maggiore lo si trova per la variabile *volume* che interpretiamo quindi come la variabile con la più alta variabilità mentre la variabile quantitativa continua più asimmetrica risulta sempre essere *volume*. Infatti, dallo studio della skewness (indice di asimmetria di Fisher) effettuato con una function simile a quelle prima descritte, emergono i seguenti valori:

attribute	skew
sales	0.72
volume	0.88
median_price	-0.36
listings	0.65
months_inventory	0.04

In particolare la variabile *volume* assume una asimmetria positiva; si può anche osservare che la variabile *median_price* assume l'assimmetria negativa maggiore. Di seguito il frammento di codice relativo al calcolo della skewness: si è utilizzati la library *moments* che consente di effettuare il calcolo della skewness con l'apposita funzione.

```
library (moments)
```

```
sk_index = function (df){
  measurements = data.frame( attributes = character (),
                             skew = double ()
                           )
  for (i in 1:ncol(df)){
    names = colnames(df)[i]
    sk_temp = data.frame( attribute = names,
                         skew = round(skewness(df[, i ]), digits =2)
                       )
    measurements = rbind (measurements, sk_temp)
  }
  return (measurements)
}

sk_index( quantiv_data )
```

1.2.1 Analisi di una variabile quantitativa a scelta: volume

La variabile *volume*, che esprime il valore totale delle vendite, assume valori nell'intervallo tra 8 e 83 milioni di dollari. Come scelta del range per la suddivisione in classi, si è optati per il valore 10 ottenendo un suddivisione da 0 a 90 andando

a creare la variabile *volume_cl*. Di seguito le righe di codice inerenti alla suddivisione in classi, alla costruzione del grafico a barre corrispondente e al calcolo dell'indice di Gini:

```
max_sales = max(data_texas$volume)
min_sales = min(data_texas$volume)
print(max_sales)
print(min_sales)

data_texas$volume_cl = cut(data_texas$volume,
                           breaks = c(0, 10, 20, 30, 40, 50, 60, 70, 80, 90))
head(data_texas)
freq_analysis(data_texas, "volume_cl")#Freq
Gini_sales = Gini(data_texas$volume)#Gini index (from DescTools library)
print(Gini_sales)

#Histogram
personal_theme = theme(plot.title = element_text(hjust = 0.5))

ggplot(data=data_texas, aes(x=volume_cl)) +
  geom_bar(col = "black", fill = "blue") +
  geom_text(stat='count', aes(label =..count..),
           vjust=-0.3, position = position_dodge(width=0.9)) +
  scale_y_continuous() +
  ggtitle("volume_cl: absolute frequency distribution") +
  personal_theme
```




Figura 1: Grafico a barre della distribuzione di frequenze assolute delle classi di valore di vendita espresse dalla variabile *volume_cl*.

1.2.2 Indice di Gini: variabile city

Il calcolo dell'indice di Gini G' , per la variabile *city*, è 1 avendo già osservato che le quattro modalità della variabile *city* assumono tutte la stessa frequenza relativa. Infatti, ricordando che

$$G' = \frac{G}{(J-1)/J}, \quad G = 1 - \sum_{j=1}^J f_j^2,$$

segue che

$$G = 1 - \sum_{j=1}^J f_j^2 = 1 - \sum_{j=1}^4 \left(\frac{60}{240} \right)^2 = 1 - 4 \frac{1}{16} = 1 - \frac{1}{4} = \frac{3}{4},$$

$$G' = \frac{\frac{3}{4}}{\frac{3}{4}} = 1.$$

1.2.3 Analisi probabilistica

Si richiede, pescata una riga a caso dal dataset, di determinare le seguenti probabilità:

1. la riga riporti la città di *Beaumont*
2. la riga riporti il mese di *Luglio*
3. la riga riporti il mese di *dicembre* dell'anno 2012

Assumendo un'equiprobabilità nel pescare una riga a caso, indichiamo con Ω l'insieme dei casi elementari costituito da ogni singola riga del dataset e con $\mathcal{P}(\mathcal{A})$ l'algebra delle parti su Ω come l'insieme degli eventi possibili. Pertanto dato un generico evento $E \in \mathcal{P}(\mathcal{A})$, segue che

$$\mathbb{P}(E) = \frac{|E|}{|\Omega|} = \frac{|E|}{240}.$$

Indiciando gli eventi di nostro interesse come

$$A = \{\text{Beaumont}\}, \quad B = \{\text{Luglio}\}, \quad C = \{\text{dicembre 2012}\},$$

abbiamo che

$$\mathbb{P}(A) = \frac{60}{240} = \frac{1}{4}, \quad \mathbb{P}(B) = \frac{20}{240} = \frac{1}{12}, \quad \mathbb{P}(C) = \frac{4}{240} = \frac{1}{60},$$

dove per la determinazione di $|B| = 20$ e $|C| = 4$ si sono usate le seguenti righe di codice in cui si effettuano filtri sul dataset:

```
data_texas %>% filter(month==7)
data_texas %>% filter(year==2012 , month==12)
```

1.2.4 Stima del prezzo medio

Possiamo determinare una nuova colonna che stima il prezzo medio di vendita P_m per la rispettiva riga fissata del dataset come segue:

```
data_texas$mean_price = (data_texas$volume*1000000) / data_texas$sales
data_texas
```

Si è trattato di implementare la seguente formula matematica in cui abbiamo considerato le variabili *volume* e *sales* indicate qui con v e s :

$$P_m = \frac{v}{s} 10^6.$$

La presenza del fattore di un milione è dovuto al fatto che la variabile *volume* nel dataset è una espressa quantità nell'ordine dei milioni.

1.2.5 Stima di un indicatore di efficacia

Possiamo definire un indicatore che stima l'efficacia E degli annunci di vendita come

$$E = \frac{s}{l},$$

dove s e l sono rispettivamente le variabili *sales* e *listings*. Essendo s e l numeri reali positivi, possiamo interpretare l'indicatore E come segue: più E tende a 1, più il numero di vendite e di annunci era simile (in altre parole è bastato un singolo o pochi annunci per la vendita di una casa).

1.2.6 dplyr summary

Per la creazione di summary raggruppate si è adottata la seguente sintassi:

```
data_texas %>%  
  group_by(city) %>%  
  summarise(var=var( sales ), mean=mean(sales))
```

```
data_texas %>%  
  group_by(year) %>%  
  summarise(var=var( sales ), mean=mean(sales))
```

```
data_texas %>%  
  group_by(month) %>%  
  summarise(var=var( sales ), mean=mean(sales))
```

In questi esempi prima riportati si va a calcolare la deviazione standard e la media per ogni città. In modo analogo si è proceduto per le variabili *year* e *month*.

1.3 Grafici con ggplot2

In questa sezione riportiamo alcuni grafici relative alle richieste del problema assieme a qualche altra considerazione ritenuta interessante. Per lo studio della distribuzione del valore totale delle vendite tra le varie città e sui vari anni si è optati per la costruzione di una time series così come la costruzione della line chart di una variabile a scelta (variabile *sales*) su vari periodi storici.

```
#### Graphics using ggplot2 ####
```

```
#1: median_price boxplot  
ggplot( data_texas , aes(x=as.factor( city ), y=median_price)) +  
  geom_boxplot( fill =" slateblue ", alpha=0.2) +  
  xlab(" city ")
```

```
#2: sales & volume & median_price timeseries  
data_texas_with_date =
```

```
data_texas$date <- as.yearmon(paste( data_texas$year , data_texas$month), "%Y %m")
```

```
data_texas %>%  
  ggplot( aes(x = date, y = sales , color = city , group = city )) +  
  geom_line() + geom_point() +  
  theme(panel.grid.minor = element_blank (), legend.position = "bottom")
```

```
data_texas %>%  
  ggplot( aes(x = date, y = volume, color = city , group = city )) +  
  geom_line() + geom_point() +  
  theme(panel.grid.minor = element_blank (), legend.position = "bottom")
```

```
data_texas %>%  
  ggplot( aes(x = date, y = median_price, color = city , group = city )) +  
  geom_line() + geom_point() +  
  theme(panel.grid.minor = element_blank (), legend.position = "bottom")
```

#3:

```
data_texas %>%  
  ggplot(aes(x=factor(month), y=sales , fill =city , group= interaction ( city , year ))) +  
  geom_col(position = "stack") +  
  theme_minimal() +  
  facet_wrap(~year, ncol=5, scales="free") +  
  theme(panel.grid.minor = element_blank (), legend.position = "bottom")
```

#Normalized version: taking position parameter as " fill "

```
data_texas %>%  
  ggplot(aes(x=factor(month), y=sales , fill =city , group= interaction ( city , year ))) +  
  geom_col(position = " fill ") +  
  theme_minimal() +  
  facet_wrap(~year, ncol=5, scales="free") +  
  theme(panel.grid.minor = element_blank (), legend.position = "bottom")
```

#4: sales line chart

```
data_texas %>%  
  ggplot(aes(x = date, y = sales , color = city , group = city )) +  
  geom_line() + geom_point() +  
  theme(panel.grid.minor = element_blank (), legend.position = "bottom")
```




Figura 2: (Boxplot del prezzo mediano, quesito 1): boxplot per confrontare la distribuzione del prezzo mediano delle case tra le varie città.




Figura 3: (Distribuzione valore totale vendite, quesito 2): confronto tra le distribuzioni del valore totale delle vendite in milioni di dollari tra le varie città sui vari anni. Possiamo notare che Tyler è la città in cui si sono registrate i valori più alti della variabile *volume*.




Figura 4: (Line chart variabile a scelta, quesito 4): confronto sull'andamento totale delle vendite sull'intero periodo. Per le città di Tyler e Bryan-College Station emerge un grande numero di vendite durante metà anno (periodo maggio-giugno) mentre le vendite decrescono in prossimità di inizio anno. La città col minor numero di vendite è stata Wichita Falls nei cinque anni considerati.




Figura 5: Confronto tra le distribuzioni del prezzo mediano tra le varie città sui vari anni. Si può osservare che la città in cui si sono registrati i valori più alti è Bryan-College Station, mentre Wichita Falls è quello in cui si sono registrati gli andamenti inferiori.




Figura 6: (Grafico a barre non normalizzato, quesito 3): grafici a barre sovrapposte (non normalizzati) per ogni anno per confrontare il totale delle vendite nei dodici mesi in base alle quattro città.



Figura 7: (Grafico a barre normalizzato, quesito 3): grafici a barre sovrapposte (normalizzati) per ogni anno per confrontare il totale delle vendite nei dodici mesi in base alle quattro città.